Proyecto: Implementación CompuComputacional en R Para el Análisis Descriptivo y Caracterización de Datos Agrupados

Alcocer Elías Daniel
Universidad de Guanajuato
DICIS
Irapuato, Guanajuato, México
d.alcocerelias@ugto.mx

Azuara Yáñez Cecil Quimey
Universidad de Guanajuato
DICIS
León, Guanajuato, México
cq.azuarayanez@ugto.mx

Castro Gutiérrez Héctor
Universidad de Guanajuato
DICIS
Irapuato, Guanajuato, México
h.castrogutierrez@ugto.mx

Jaime Jiménez Emmanuel
Universidad de Guanajuato
DICIS
Irapuato, Guanajuato, México
e.jaimejimenez@ugto.mx

Rincón García Luis Antonio
Universidad de Guanajuato
DICIS
Irapuato, Guanajuato, México
la.rincon.garcia@ugto.mx

***Resumen*—El presente proyecto tiene como objetivo aplicar las principales fórmulas y conceptos abordados a lo largo del curso con ayuda del software R, con el objetivo de obtener resultados estadísticos precisos mediante las fórmulas abordadas durante el curso. El uso de R permite automatizar cálculos, minimizar errores humanos y facilitar la interpretación de los datos mediante funciones optimizadas y representaciones gráficas.**

Durante el desarrollo del proyecto se implementaron diversas fórmulas implementadas durante el curso, incluyendo medidas de tendencia central, dispersión, momentos estadísticos, probabilidades y transformaciones de variables. Cada una de estas fórmulas fue programada en el software utilizando scripts que permiten verificar la correcta aplicación de los conceptos teóricos, lo que permitió analizar datos de manera clara y estructurada.Al momento de obtener los resultados con el software, se confirmó la precisión del software y mostrando la utilidad del software R como herramienta de análisis académico y profesional.

Este proyecto demuestra la importancia de integrar conocimientos teóricos con métodos computacionales, las cuales fortalecen las habilidades de análisis estadístico, programación y verificación de resultados. La aplicación del lenguaje R no solo agiliza el proceso de cálculo, sino que también amplía las posibilidades de exploración y comunicación de datos.

I. Introducción

La **estadística** es la ciencia del conteo de eventos, análisis de estado y obtención de información. Genera datos de una forma directa o indirecta. Los valores de esta pueden ser numéricos o cualitativos.

Una **tabla de distribución de frecuencias** es una herramienta estadística utilizada para organizar y resumir un conjunto de datos, clasificandolos en intervalos o categorías y mostrando la frecuencia con la que ocurren los valores de cada intervalo.

Pasos para la obtención de una tabla de distribución de frecuencias:

1. Recopilar y ordenar los datos

Utilizando cualquier método de obtención de datos. Para datos cuantitativos, ordenarlos de menor a mayor.

2. Determinar el número de clases

Se basa en el tamaño de la muestra **(N)**, propuesta por Herbert Sturges en 1926. La ecuación 1 calcula el número de clases para una tabla de distribución de frecuencias.

$$K = 1 + \log_2(N) \tag{1}$$

Donde:
N - Número de datos

Esta fórmula es especialmente útil para muestras pequeñas o moderadas; ya que asume una distribución normal de los datos.

3. Calcular el rango (R)

El **rango (R)** es la diferencia entre el valor máximo y el valor mínimo de los datos. La ecuación 2 calcula el rango para una tabla de distribución de frecuencias.

$$R = X_{\text{max}} - X_{\text{min}} \tag{2}$$

Donde:
X_{max} - Valor máximo
X_{min} - Valor mínimo

4. Calcular la amplitud de clase (A)

La **amplitud de clase (A)** se obtiene dividiendo el rango por el número de clases. La ecuación 3 calcula la amplitud para una tabla de distribución de frecuencias.

$$A = \frac{R}{K} \tag{3}$$

Donde:
R - Rango
k - Número de clases

5. Obtención de los intervalos de clase

Los **amintervalos de clase** se obtienen sumando la amplitud de la clase al límite inferior de cada intervalo.

6. Cálculo de la marca de clase

La **marca de clase** es el valor que representa a cada intervalo dentro de la tabla de distribución de frecuencias. Se obtiene calculando el punto medio del intervalo, es decir, promediando el límite inferior y el límite superior de cada clase. La ecuación 4 calcula la marca de clase para una tabla de distribución de frecuencias.

$$x_i = \frac{L_{\text{inf}} + L_{\text{sup}}}{2} \tag{4}$$

Donde:
L_{inf} - Límite inferior de la clase
L_{sup} - Límite superior de la clase

7. Cálculo de frecuencias

Las **frecuencias** son el número de veces que cada valor de un dato o categoría se repite en un conjunto de datos. Estas frecuencias permiten resumir y organizar los datos, facilitando su análisis y la identificación de patrones o tendencias.

- **Frecuencia o frecuencia absoluta (F):** Es el número de veces que se repite un número en un conjunto de datos. Indica cuantos datos hay en cada intervalo.

- **Frecuencia acumulada (FA):** Se obtiene sumando progresivamente las frecuencias.

- **Frecuencia relativa (FR):** Indica las veces que se repite un número en un conjunto de datos respecto al total. Se obtiene dividiendo la frecuencia absoluta por el total de los datos.

- **Frecuencia relativa acumulada(FRA):** Se obtiene sumando progresivamente de las frecuencias relativas.

Un **histograma de frecuencias** es un gráfico que representa las distribuciones de frecuencias a través de una gráfica de barras. Una **gráfica de barras** es una representación de datos categóricos mediante rectángulos cuya altura es proporcional a

la frecuencia de cada categoría.

En la figura 1 se muestra un ejemplo de histograma:

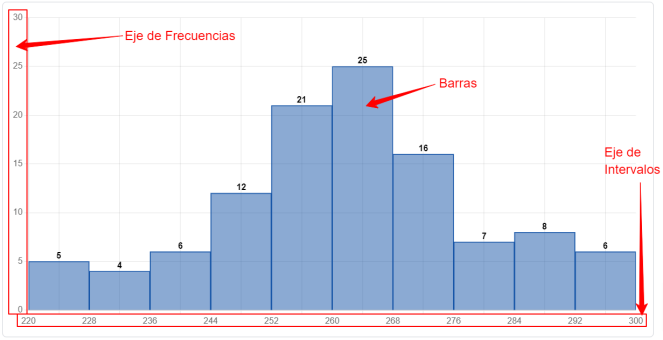


Figura 1. Ejemplo de histograma. [1]

Las **medidas de tendencia central** nos indican hacia que valores tiende al comportamiento de una variable cuantitativa. Buscan establecer un punto en torno al cual se distribuyen los datos. Facilitan el análisis comparativo entre conjuntos de datos, proporcionando una idea de ”promedio”.

Una **medida de dispersión** son valores definidos respecto de un valor de referencia. Estos son valores numéricos que nos dicen que tan alejados se encuentran los datos de un punto con respecto a su centro (generalmente la media).

Las **Medidas de posición** dan una idea del comportamiento de la distribución de todos los datos.

El **promedio** es un valor típico o representativo de un conjunto de datos. Estos valores tienden a localizarse en el centro del conjunto de datos. También son denominados **medidas de tendencia central**.

1. Media aritmética

Indica el punto de equilibrio e los datos. Representa el valor que se obtiene al sumar todos los datos de un conjunto e datos y dividimos entre el número total de observaciones. La ecuación 5 calcula la media aritmética para un conjunto de datos agrupados.

$$\bar{x} = \mu = \frac{\sum_{i=1}^{N} x_i}{N} \tag{5}$$

Donde:
x_i - Cada dato
N - Número de observaciones

En un conjunto de observaciones, la suma algebraíca de las observaciones de estas respecto a la media es cero.

2. Media armónica (H)

Es una medida de tendencia central que se utiliza cuando los datos representan tasas, velociades y proporciones. La ecuación 6 calcula la media armónica para un conjunto de datos agrupados.

$$H = \frac{N}{\sum_{i=1}^{N} \frac{fi}{x_i}} \tag{6}$$

Donde:
f_i - Frecuencia
X_i - Cada dato
N - Número de observaciones

La media armónica para datos agrupados se utiliza cuando los datos están organizados en una tabla de distribución de frecuencias. En este caso, no se trabaja con cada valor individual, sino con clases o valores representativos (como marcas de clase) y sus respectivas frecuencias absolutas.

3. Media geométrica (G)

Se define como el valor que mantiene constante el producto ponderado de las observaciones por sus frecuencias. La ecuación 7 calcula la media geométrica para un conjunto de datos agrupados.

$$G = \left(\prod_{i=1}^{k} x_i^{f_i} \right)^{\frac{1}{N}} \tag{7}$$

Donde:
f_i - Frecuencia
X_i - Cada dato
N - Número de observaciones

4. Media cuadrática (C)

Se define como una medida estadística que se usa para calcular un valor promedio que toma en cuenta la magnitud de los datos sin importar su signo.. La ecuación 8 calcula la media cuadrática para un conjunto de datos agrupados.

$$x_{\text{rms}} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} f_i x_i^2} \tag{8}$$

Donde:
f_i - Frecuencia
X_i - Cada dato
N - Número de observaciones

5. Mediana (Me)

Divide el conjunto de datos en dos partes de igual tamaño. Robusta ante valores atípicos y asimetrías. Minimiza la suma de observaciones absolutas y es adecuada cuando la media se ve afectada por outliers o distribuciones sesgadas. La ecuación 10 calcula la media geométrica para un conjunto de datos agrupados.

$$M_e = L_j + \left(\frac{\frac{N}{2} - F_{j-1}}{f_j}\right) C \tag{9}$$

Donde:
L_j - Límite inferior de la clase mediana
$F_j - 1$ - Frecuencia de la clase mediana
C - Amplitud de la clase

6. Moda (Mo)

Se estima por la interpolación en la clase modal (la de mayor frecuencia). La ecuación 10 calcula la moda para un conjunto de datos agrupados. Se requiere el límite inferior de la clase modal, amplitud de la clase, y frecuencias de la clase modal y sus vecinas.

$$M_o = L_j + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2}\right) C \tag{10}$$

Donde:
$\Delta_1 = f_m - (f_m - 1)$
$\Delta_2 = f_m - (f_m + 1)$
L_j - Límite inferior de la clase moda
$f_m - 1$ - Frecuencia de la clase anterior
$f_m + 1$ - Frecuencia de la clase posterior a la clase moda
f_m - Frecuencia de clase moda
C - Amplitud de clase

Consideraciones

- **Asimetría unimodal:** Es una distribución de probabilidad que presenta un único pico o moda. Esto significa que los datos se agrupan en torno a un valor central, formando un único pico prominente en la curva de distribución.
  Media $\approx$ Mediana $\approx$ Moda

- **Sesgo positivo:** Ocurre cuando una distribución de datos está desplazada hacia la izquierda, de modo que la cola se extiende hacia valores mayores.
  Moda $<$ Mediana $<$ Media

- **Sesgo negativo** Ocurre cuando una distribución de datos está desplazada hacia la derecha, de modo que la cola se extiende hacia valores menores.
  Moda $>$ Mediana $>$ Media

7. Raíz cuadrada media (RCM)

También llamada **media cuadrática** representa el promedio de los valores cuadrados de un conjunto, seguido de la raíz cuadrada. La ecuación 11 calcula la raíz cuadrada media para un conjunto de datos

agrupados.

$$RCM = \sqrt{\frac{1}{N}\sum_{i=1}^{k} f_j x_i^2} \tag{11}$$

Donde:
x_i^2 - Número de clases al cuadrado
f_j - Frecuencia de clase
N - Número de observaciones

Cuantiles

Son medidas de posición que dividen un conjunto de datos ordenados en partes iguales y permiten identificar valores representativos en distintas proporciones.

- **Cuártiles:** Dividen en cuatro partes iguales, se denotan como: Q_1, Q_2, Q_3
- **Deciles:** Dividen en diez partes iguales, se denotan como: $D_1, D_2, D_3 ... D_9$
- **Percentiles:** Dividen en cien partes iguales, se denotan como: $P_1, P_2, P_3 ... P_{99}$

La ecuación 12 calcula la posición del cuantil para un conjunto de datos agrupados.

$$Q_k = L + C\left(\frac{qN - F}{f}\right) \tag{12}$$

Donde:
L - Límite inferior del intervalo cuantil
C - Amplitud del intervalo
q - Cuantil (entre 0 y 1), $q = \frac{k}{m}$
N - Número de observaciones
K - Número del cuantil
m - Número de divisiones (4, 10, 100)
F - Frecuencia acumulada anterior al intervalo cuantil
f - Frecuencia del intervalo cuantil

1. Rango semi-intercuartil (RSI)
Desviación cuartil (Q)/promedio cuartílico

Es una medida de dispersión que se utiliza para describir la variabilidad de un conjunto de datos entorno a la mediana, siendo menos sensible a valores extremos. Es la mitad del **rango intercuartilico (IQR)**, es decir, la distancia entre el tercer y el primer cuartil. La ecuación 13 calcula el rango semi-intercuartil para un conjunto de datos agrupados.

$$RSI = SIQR = \frac{Q_3 - Q_1}{2} \tag{13}$$

Donde:
Q_1 - Cuartil 1
Q_3 - Cuartil 3

Un SIQR pequeño indica que el 50 % de los datos centrales están muy cerca de la mediana, lo que se sugiere una baja dispersión.

2. Rango percentil 10-90
Rango semi-percentil 10-90

Es una medida de dispersión que indica la diferencia ebtre el valor del percentil 90 (P_{90}) y el valor del percentil 10 (P_{10}). Esta medida captural el rango que abarca 10 % de los valores más bajos. Esta medida es robusta frente a los valores extremos (outliers).

Proporciona una media más fiable de la dispersión del núcleo de la distribución. La ecuación 14 calcula el rango semi-percentil para un conjunto de datos agrupados.

$$SPR = \frac{P_{90} - P_{10}}{2} \tag{14}$$

Donde:
P_{10} - Percentil 10
P_{90} - Percentil 90

Representa la desviación promedio de los datos con respecto al cdntro de la distribución (basado en percentiles), excluyendo los extremos. Proporciona una media de la dispersión que es aun más resistente a valores extremos que el rango semi-cuartilico.

3. Desviación media (DM)

También llamada **desviación absoluta promedio**, es una medida de dispersión que indica que tan separados están los datos de un conjunto con respecto a su media. El fundamento de la desviación media es proporcionar un resumen de la variabilidad de los datos.

Un valor bajo indica que los datos estan muy agrupados al rededor de la media. La ecuación 15 calcula la desviación media para un conjunto de datos agrupados.

$$DM = \frac{1}{N}\sum_{i=1}^{k} f_j \left|x_j - \mu\right| \tag{15}$$

Donde:
f_j - Frecuencias de clase
X_j - Marcas de clase
μ - Media aritmética de las observaciones
N - Número de observaciones

4. Varianza (σ^2)

Es el promedio de las diferencias al cuadrado entre cada observación y la media del conjunto. Se elevan al cuadrado por dos razones:

- Para que las desviaciones negativas no se anulen con las positivas.
- Para dar más peso a las desviaciones más grandes.

La ecuación 17 calcula la varianza para un conjunto de datos agrupados.

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{k} f_j (x_i - \mu)^2 \tag{16}$$

Donde:
X_i - Marcas de clase
f_j - Frecuencias de clase
N - Número de observaciones
μ - Media aritmética de las observaciones

5. Desviación estándar (σ)

Es una medida de extensión o variabilidad en la estadística descriptiva. Se utiliza para calcular la variación o dispersión en la que los puntos de datos individuales difieren de la media. Es la distancia promedio de cada dato del conjunto.

- Es la raíz cuadrada de la varianza.
- Es la medida más utilizada.
- Al tomar la raíz cuadrada, se regresa a las unidades origianles de los datos, lo que hace más fácil de interpretar.

La ecuación 17 calcula la desviación estándar para un conjunto de datos agrupados.

$$\sigma = \sqrt{\frac{1}{N}\sum_{i=1}^{k} f_j (x_i - \mu)^2} \tag{17}$$

Donde:
X_i - Marcas de clase
f_j - Frecuencias de clase
N - Número de observaciones
μ - Media aritmética de las observaciones

6. Z-Score o Unidad estándar (Z_i)

Se utiliza para comparar valores que pertenecen a diferentes conjuntos de datos, transformándolos a una escala común sin unidades. Indica cuantas desviaciones estándar se encuentra un valor x, por encima o por debajo de la media de su conjunto.La ecuación 18 calcula el Z-Score o Unidad estándar para un conjunto de datos agrupados.

$$Z_i = \frac{x_i - \mu}{\sigma} \tag{18}$$

Donde:
X_i - Cada observación del conjunto
μ - Media aritmética
σ - Desviación estándar

- $Z_i > \mathbf{0}$: El valor está por encima de la media.
- $Z_i < \mathbf{0}$: El valor está por debajo de la media.
- $Z_i = \mathbf{0}$: El valor coincide con la media.

7. Coeficiente de dispersión (V)

Es una medida de dispersión adimensional, basada en la desviación estándar. Expresa la desviación estándar como un porcentaje de lo que mide.La ecuación 19 calcula el coeficiente de dispersión para un conjunto de datos agrupados.

$$V = \left(\frac{\sigma}{\mu}\right) \times 100\,\% \tag{19}$$

Donde:
σ - Desviación estándar
μ - Media aritmética

8. Coeficiente de variación cuartil Rango itercuartilico (IQR)

Basado en el primer y tercer cuartil. Es el porcentaje de la dispersión central relativa medida por cuartiles.La ecuación 20 calcula el rango intercuartílico para un conjunto de datos agrupados.

$$CQV = \left(\frac{Q_3 - Q_1}{Q_3 + Q_1}\right) \times 100\,\% \tag{20}$$

Donde:
Q_1 - Primer cuartil
Q_3 - Tercer cuartil

- No depende de unidades y es resistente a valores extremos.
- 0 % (sin dispersión) a valores moderados/altos según la heterogeneidad de la muestra.

Momentos

Los **momentos** son un conjunto de medidas cuantitativas que describen las características de la forma de una distribución de probabilidad. Proporcionan un resumen numérico de como se distribuyen los datos.

Describe la distribución de la ”masa”de probabilidad y nos permiten definir formalmente conceptos clave como la tendencia central, la dispersión, la simetría y el apuntamiento. Se calculan en relación a la media o alguna otra medida de dispersión.

1. Momentos respecto al origen

El K-ésimo momento respecto al origen (o momento crudo) de una variable aleatoria x, denotado como m_k ó μ_k, se define como el valor esperado de x elevado a la porgtencia k. La ecuación 21 calcula los momentos respecto al origen para un conjunto de datos agrupados.

$$m_k = \frac{1}{N} \sum_{i=1}^{k} f_i \, (x_i - \mu)^k \tag{21}$$

Donde:
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
k - Momento (1,2,3,...)

2. Momentos centrales

El K-ésimo momento central o **momento respecto a la media**, se denota por μ_k es el valor esperado de la desviación de x respecto a su media (μ), elevada a la potencia k. La ecuación 22 calcula los momentos respecto a la media para un conjunto de datos agrupados.

$$\mu_K = m_K = \frac{1}{N}\sum_{i=1}^{k} f_i\,(x_i - \mu)^K \qquad (22)$$

Donde:
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
μ - Media aritmética

2.1. Primer momento central respecto a la media

Por definición el primer momento central respecto a la media (μ_1) siempre es cero: $\mu - \mu = 0$

2.2 . Segundo momento central respecto a la media (varianza)

Mide la dispersión o amplitud de los datos al rededor de la media. La ecuación 23 calcula el segundo momento central respecto a la media para un conjunto de datos agrupados.

$$\mu_2 = \sigma^2 = m_2 = \frac{1}{N}\sum_{i=1}^{k} f_i\,(x_i - \mu)^2 \qquad (23)$$

Donde:
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
μ - Media aritmética

- Se denota por σ^2.
- Un σ^2 pequeño significa que los datos están muy agrupados cerca de la media.
- Un σ^2 grande significa que los datos están muy separados.
- Su raíz cuadrada es la desviación estándar (σ).

2.3 Tercer momento central respecto a la media Asimetría (sesgo)

El tercer momento central (μ_3) es el sesgo (skewmess) de la distribución, es comúnmente denotada por γ_1. La ecuación 24 calcula ewl tercer momento central respecto a la media para un conjunto de datos agrupados.

$$\mu_3 = \gamma_1 = m_3 = \frac{1}{N}\sum_{i=1}^{k} f_i\,(x_i - \mu)^3 \qquad (24)$$

Donde:
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
μ - Media aritmética

- La asimetría indica si la distribuación es sesgada a la izquierda o a la derecha.
- Si el valor es **positivo**, es asimétrica a la derecha.
- Si el valor es **negativo**, es asimétrica a la izquierda.
- Si el valor es **cercano a cero**, su distribución es aproximadamente simétrica.

2.4 Cuarto momento central respecto a la media Curtosis

Indica el grado de concentración de los datos respecto a la media. La ecuación 25 calcula Cuarto momento central respecto a la media para un conjunto de datos agrupados.

$$\mu_4 = \beta_2 = m_4 = \frac{1}{N}\sum_{i=1}^{k} f_i\,(x_i - \mu)^4 \qquad (25)$$

Donde:
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
μ - Media aritmética

- Si el valor es **cercano a 3**, los datos tienen una distribución normal.
- Si el valor es **menor a 3**, los datos tienen una distribución normal.
- Si el valor es **mayor a 3**, la distribuación está muy concentrada al rededor de la media.

3. Momentos estandarizados
Momentos adimensionales

Se utilizan para describir la forma de la distribuación (independientemente de su escala o dispersión), se utilizan los momentos centrales respecto a la media. Estos se obtienen al dividir el momento central (μ_k) por la desviación estándar (σ) elevada a la potencia k. La ecuación 26 calcula el cuarto momento central respecto a la media para un conjunto de datos agrupados.

$$a_k = \frac{\mu_k}{\sigma^k} = \frac{\sum_{i=1}^{k} f_i(x_i - \mu)^k}{\left(\sum_{i=1}^{k} f_i(x_i - \mu)^2\right)^{k/2}} \tag{26}$$

Donde:
k - Momento (1,2,3,...)
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
μ - Media aritmética

Sesgo

El **sesgo (skewness)** mie la asimetría de la distribuación. Es una medida asimétrica que indica hacia que lado de la distribuación se extienden los datos de manera desigual. Cuantifica la asimetría de la distribución respecto de su media.

- **Simetría (Sesgo ≈ 0):** Cuando la distribución es simétrica, se cumple que:

$$\text{Media} \approx \text{Mediana} \approx \text{Moda}.$$

- **Sesgo positivo (Sesgo > 0):** Si la distribución presenta una cola más larga hacia la derecha, entonces:

$$\text{Media} > \text{Mediana}.$$

- **Sesgo negativo (Sesgo < 0):** Si la distribución presenta una cola más larga hacia la izquierda, entonces:

$$\text{Media} < \text{Mediana}.$$

La ecuación 27 calcula el sesgo para un conjunto de datos agrupados.

$$\gamma_1 = \frac{\sum_{i=1}^{k} f_i(x_i - \mu)^3}{\sigma^3} = \frac{\mu_3}{\sigma^3} \tag{27}$$

Donde:
γ_1 - Coeficiente de Fisher, es el momento estandarizado σ - Desviación estándar
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
μ - Media aritmética

- Si $|\gamma_1| < 0{,}5$, se considera un sesgo bajo.
- Si $0{,}5 < |\gamma_1| < 1$, se interpreta como un sesgo moderado.
- Si $|\gamma_1| > 1$, se clasifica como un sesgo alto.

Como se observa en la Figura 2, se ilustran los distintos niveles de sesgo según el valor de $|\gamma_1|$.

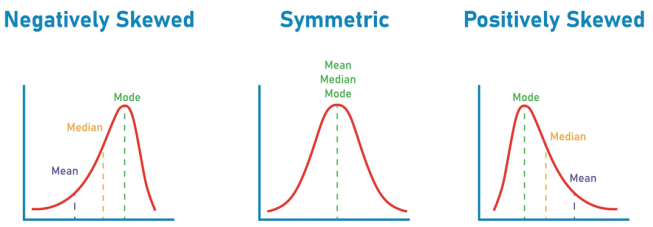


Figura 2. Tipos de sesgo

En istribuciones sesgadas, la media tiende a desplazarse hacia el lado de la cola más larga en comparación con la moda (el valor más frecuente).

Una forma simple de medir este sesgo es **medir la diferencia entre la media y la moda**.

Coeficiente de sesgo de Pearson:

Es una prueba que mide la relación estadística entre dos variables continuas. Si la asociación entre los elementos no es lineal, entonces el coeficiente no se encuentra representado adecuadamente.

A continuación se presentan las principales fórmulas para calcular el sesgo de una distribución de datos:

1. Primer coeficiente de sesgo de Pearson:

Mide la asimetría de una distribución basándose en la media, la mediana y la desviación estándar. La ecuación 28 calcula el primer coeficiente de sesgo de Pearson para un conjunto de datos agrupados.

$$Sesgo_1 = \frac{\mu - Moda}{\sigma} \tag{28}$$

Donde:
μ - Media aritmética
$Moda$ - Valor más frecuente
σ - Desviación estándar

- $Sesgo_1 = 0$: La distribución es **simétrica**.
- $Sesgo_1 > 0$: La distribución presenta sesgo **positivo** hacia a la derecha.
- $Sesgo_1 < 0$: La distribución presenta sesgo **negativo** hacia la izquierda.

2. Segundo coeficiente de sesgo de Pearson:

Mide la asimetría de una distribución basándose en la media, la mediana y la desviación estándar. La ecuación 29 calcula el segundo coeficiente de sesgo de Pearson para un conjunto de datos agrupados.

$$Sesgo_2 = \frac{3(\mu - Mediana)}{\sigma} \tag{29}$$

Donde:
μ - Media aritmética
$Mediana$ - Valor central del conjunto de datos
σ - Desviación estándar

- $Sesgo_2 = 0$: La distribución es **simétrica**.
- $Sesgo_2 > 0$: La distribución presenta sesgo **positivo**.
- $Sesgo_2 < 0$: La distribución presenta sesgo **negativo**.

3. Coeficiente cuartil de sesgo:

Divide la distribución en cuartiles Q_1 (primer cuartil), Q_2 (mediana) y Q_3 (tercer cuartil), y mide la asimetría relativa de los datos en torno a la mediana. La ecuación 30 calcula el coeficiente cuartil de sesgo para un conjunto de datos agrupados.

$$3k_B = \frac{Q_3 + Q_1 + 2Q_2}{Q_3 - Q_1} \tag{30}$$

Donde:
Q_1 - Primer cuartil
Q_2 - Segundo cuartil
Q_3 - Tercer cuartil

4. Coeficiente percentiltil de sesgo:

Divide la distribución en cuartiles Q_1 (primer cuartil), Q_2 (mediana) y Q_3 (tercer cuartil), y mide la asimetría relativa de los datos en torno a la mediana. La ecuación 31 calcula el coeficiente percentil de sesgo para un conjunto de datos agrupados.

$$Sk_P = \frac{P_{90} + P_{10} - 2P_{50}}{P_{90} - P_{10}} \tag{31}$$

Donde:
P_{10} - Percentil diez
P_{50} - Percentil cincuenta
P_{90} - Percentil noventa

Robustez vs sensibilidad

No todas las distribuciones son "limpias". La presencia de valores atípicos (outliers) pueden distorcionar en las medidas estadísticas.

- **Fisher (momentos)**: Usa todos los datos y es una medida completa.
- **Bowley (cuartiles)**: Usa solo el 50 % central de los datos, es muy robusto e ignora por completo los datos extremos.
- **Kelly (percentiles)**: Usa el 80 % de los datos, es un balance, más robusto que Fisher, pero más sensible que Bowley.

En la Figura 3 se presenta una tabla resumen de los diferentes tipos coeficientes de sesgo, indicando los valores calculados y su interpretación correspondiente. Esta tabla permite comparar de manera clara el sesgo de la distribución según distintas medidas, incluyendo los coeficientes de Pearson, el coeficiente cuartílico y el coeficiente percentil.

Característica	Fisher	Bowley	Kelly
Nombre Completo	Coef. De Momentos	Coef. Cuartil	Coef. Percentil
Base del Cálculo	Momentos (Media)	Cuartiles (Mediana)	Percentiles (Mediana)
Fórmula	$\gamma_1 = \frac{\mu_3}{\sigma^3}$	$SK_Q = \frac{Q_3+Q_1-2Q_2}{Q_3-Q_1}$	$SK_P = \frac{P_{90}+P_{10}-2P_{50}}{P_{90}-P_{10}}$
Rango de Valores	$(-\infty, +\infty)$	$[-1, +1]$	$[-1, +1]$
Datos Usados	**100 %** (Todos)	**50 %** Central	**80 %** Central
Sensibilidad a Outliers	**Muy Alta**	**Muy Baja (Robusto)**	**Baja (Balance)**
Sigla Común	γ_1 (o SK_F)	SK_B (o SK_Q)	SK_K (o SK_P)

Figura 3. Tabla comparativa de tipos de sesgo

Curtosis (kurtosis)

Mide que tan puntiaguda es en comparación con la distribución normal. Una alta curtosis indica que la varianza se debe a valores atípicos (outliers), infrecuentes y extremos, en lugar de a valores moderados y frecuentes. El sesgo y la curtosis miden lo mismo, pero usan una referencia distinta.

Referencia: La curtosis de una distribución normal es 3. Para ello, casi siempre podemos usar el exceso de curtosis. La ecuación 32 calcula la curtosis para un conjunto de datos agrupados.

$$\text{Exceso de curtosis} = \frac{\mu_4}{\sigma^4} = \text{Curtosis} - 3 \quad (32)$$

Donde:
μ - Media aritmética
σ - Desviación estándar

La **curtosis** mide la forma de la distribución de los datos, específicamente el grado de concentración de los valores alrededor de la media. Según el valor del **exceso de curtosis** se clasifican los tipos de distribución:

Basado en β_2 = Exceso de curtosis:

- **Leptocúrtica** ($\beta_2 > 0$): lepto = "delgado", pico agudo y colas pesadas. Más propensa a outliers extremos.
- **Mesocúrtica** ($\beta_2 = 0$): meso - "medio", igual que la distribución normal.
- **Platicúrtica** ($\beta_2 < 0$): platy = "Plano", pico plano y colas ligeras, menos propensa a outliers.

La Figura 4 se muestran los distintos tipos de curtosis en una distribución de datos. Destacando sus tres casos principales: **leptocúrtica**, con un pico más alto y colas más pesadas que la distribución normal; **mesocúrtica**, con forma similar a la distribución normal; y **platicúrtica**, con un pico más bajo y colas más ligeras. Esta representación visual permite comprender cómo varía la concentración de los datos alrededor de la media según el tipo de curtosis.

Coeficientes de momentos (Fisher)

Se basa en el cuarto momento, esto hace que los valores atípicos (lejos de la media) tengan un peso extremo en el cálculo. Es la medida estándar, pero la menos robusta.

Coeficientes de percentiles (Robustos)

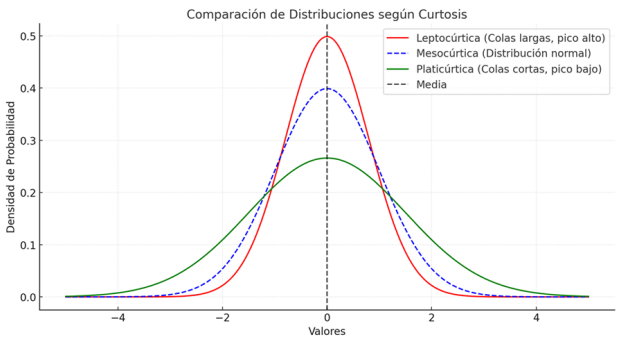


Figura 4. Tipos de curtosis

Se basan en rangos e ignoran por completo los valores extremos. Miden el apuntamiento respecto del centro de los datos, son robustos a los outliers.

1. Curtosis de momentos (Fisher β_2)

Mide el cuarto momento estandarizado, con una **referencia (normal) = 3**. La ecuación 33 calcula la curtosis de momentos de Fisher (β_2) para un conjunto de datos agrupados.

$$\beta_2 = k = \frac{\sum_{i=1}^{k} f_i(x_i - \mu)^4}{\sigma^4} = \frac{\mu_4}{\sigma^4} \tag{33}$$

Donde:
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
μ - Media aritmética
σ - Desviación estándar

- $\beta_2 > 3$: Leptocúrtica
- $\beta_2 < 3$: Platicúrtica

2. Exceso de curtosis (γ_2)

Es el másutilizado en el software. Simplemente resta 3 al de Fisher. Su **referencia (normal) = 0**. La ecuación 34 calcula la curtosis de momentos de Fisher (β_2) para un conjunto de datos agrupados.

$$\beta_2 = k - 3 = \frac{\sum_{i=1}^{k} f_i(x_i - \mu)^4}{\sigma^4} - 3 = \frac{\mu_4}{\sigma^4} - 3 \tag{34}$$

Donde:
f_i - Frecuencias de clase
x_i - Cada observación el conjunto
N - Número total de observaciones
μ - Media aritmética
σ - Desviación estándar

- $\gamma_2 > 0$: Leptocúrtica
- $\gamma_2 < 0$: Platicúrtica

3. Coeficiente: 3 percentil (k_p ó M)

Existen varias versiones, pero la más común compara el rango intercuartilico (IQR) con el rango del 10 % al 90 %. Avecesse llama **coeficiente de curtosis de Moors**.

Mide que tan comprimido está el 50 % central de los datos en relación con el 80 % central. La ecuación 35 calcula el coeficiente percentil para un conjunto de datos agrupados.

$$k_p = \frac{Q_3 - Q_1}{P_{90} - P10} \tag{35}$$

Donde:
Q_1 - Primer cuartil
Q_2 - Segundo cuartil
Q_3 - Tercer cuartil
P_{10} - Percentil diez
P_{90} - Percentil noventa

- $k_p > 0{,}525$: Leptocúrtica
- $k_p < 0{,}525$: Platicúrtica

En la Figura 5 se presenta una tabla resumen de los diferentes tipos de curtosis, indicando los valores calculados y su interpretación correspondiente. Esta tabla permite comparar de manera clara la curtosis.

En resumen, las fórmulas y coeficientes presentados en este apartado permiten caracterizar de manera completa la distribución de los datos, evaluando su tendencia central, dispersión, asimetría y forma, lo cual facilita un análisis estadístico riguroso y

Característica	Momentos (β_2)	Exceso (g_2)	Percentil (K_P)
Nombre Común	Curtosis de Fisher	Exceso de Curtosis	Coef. de Moors / Robusto
Base del Cálculo	4to Momento	4to Momento (Ajustado)	Percentiles (Cuartiles/Deciles)
Fórmula	$\frac{\mu_4}{\sigma^4}$	$\frac{\mu_4}{\sigma^4} - 3$	$\frac{Q_3 - Q_1}{P_{90} - P_{10}}$
Referencia (Normal)	**3**	**0**	≈ 0.525
Interpretación (Lepto)	> 3	> 0	> 0.525
Interpretación (Platy)	< 3	< 0	< 0.525
Sensibilidad a Outliers	**Extremadamente Alta**	**Extremadamente Alta**	**Muy Baja (Robusto)**
Uso Común	Teórico, definición	Práctico (Software)	Análisis de datos robusto

Figura 5. Tabla comparativa de tipos de curtosis

comparativo. Esta información fue utilizada en el software R para su análisis estadístico, permitiendo calcular y visualizar de manera precisa las medidas de tendencia central, dispersión, asimetría y curtosis de los datos.

II. METODOLOGÍA

1. Tabla de frecuencias
Función `crear_tabla()`

Esta función constituye el núcleo del análisis estadístico, encargándose de transformar un conjunto de datos brutos en una tabla de frecuencias completa y estructurada. Cada paso del proceso traduce conceptos teóricos de estadística descriptiva en instrucciones precisas del lenguaje R, manteniendo la rigurosidad matemática de las fórmulas originales.

Librerías requeridas

El código inicia cargando dos librerías esenciales:

- `here`: Permite manejar rutas de archivos de forma robusta e independiente del sistema operativo.
- `ggplot2`: Biblioteca para crear visualizaciones gráficas de alta calidad.

1.1 Lectura y ordenamiento de datos
Implementación en código:

```
datos <- scan(file=here("Data",
nombre_archivo), what=numeric(),
sep=",")datos.ordenados <-
sort(datos)N <- length(datos)
```

El proceso comienza leyendo el archivo de datos mediante `scan()`, que permite leer valores numéricos separados por comas. La función `here()` construye automáticamente la ruta correcta hacia la carpeta "Data", independientemente del directorio de trabajo actual. Una vez leídos, los datos se ordenan ascendentemente con `sort()`, facilitando cálculos posteriores como la identificación de valores máximos y mínimos. Finalmente, se determina el tamaño muestral N contando el número total de observaciones.

1.2 Determinación del número de clases (K)
Fórmula teórica:

Se basa en el tamaño de la muestra **(N)**. La ecuación 1 calcula el número de clases para una tabla de distribución de frecuencias.

$$K = 1 + \log_2(N)$$

Implementación en código:

```
K <- floor(1 + log2(N))
```

Esta fórmula, conocida como la **Regla de Sturges**, proporciona un número óptimo de intervalos o clases para agrupar los datos. La función `log2()` calcula el logaritmo en base 2 del tamaño muestral, y `floor()` redondea hacia abajo al entero más cercano, asegurando que K sea siempre un número entero positivo. Esta regla es particularmente efectiva para distribuciones aproximadamente normales.

1.3 Cálculo del rango y la amplitud
1.3.1 Ecuación teórica del rango (R):

Es la diferencia entre el valor máximo y el valor mínimo de los datos. A partir de la ecuación 2, la cual calcula el rango para una tabla de distribución de frecuencias.

$$R = X_{\text{máx}} - X_{\text{mín}}$$

Implementación en código:

```
rango<-max(datos.ordenados)
-min(datos.ordenados)
```

El rango representa la dispersión total de los datos, calculado como la diferencia entre el valor más grande y el más pequeño del conjunto de datos ordenados.

1.3.2 Ecuación teórica de la amplitud (A):

Se obtiene dividiendo el rango por el número de clases. En la ecuación 3 se calcula la amplitud para una tabla de distribución de frecuencias.

$$A = \frac{R}{K}$$

Implementación en código:

```
amplitud <- ceiling(rango / K)
```

La amplitud determina el ancho de cada intervalo de clase. Al dividir el rango entre el número de clases, obtenemos intervalos de tamaño uniforme. La función `ceiling()` redondea hacia arriba, garantizando que todos los datos queden incluidos dentro de los intervalos construidos.

1.4 Creación de límites y marcas de clase
Implementación en código:

```
lims.inf <- seq(min
(datos.ordenados) - 1,
max(datos.ordenados) + amplitud,
by = amplitud)
lims.inf <- lims.inf
- 0.05
lims.sup <- lims.inf[-1]
lims.sup <- lims.sup + 1
lims.inf <- lims.inf + 1
lims.inf <- lims.inf[-length
(lims.inf)]marca.de.clase <-
(lims.inf + lims.sup) / 2
```

Este paso construye los intervalos de clase siguiendo una secuencia lógica:

1. **Generación inicial**: `seq()` crea una secuencia que comienza un poco antes del valor mínimo y se extiende más allá del máximo, avanzando con pasos del tamaño de la amplitud.
2. **Ajustes finos**: Las operaciones de restar 0.05 y sumar 1 son ajustes técnicos para manejar correctamente los límites de los intervalos, asegurando que cada dato caiga exactamente en una clase sin ambigüedades en los bordes.
3. **Límites superiores**: Se obtienen desplazando la secuencia original un elemento (eliminando el primero con `[-1]`), lo que empareja cada límite inferior con su correspondiente límite superior.
4. **Eliminación del exceso**: Se remueve el último elemento de los límites inferiores para que el número de intervalos coincida con K.
5. **Marcas de clase**: Representan el punto medio de cada intervalo, calculado promediando el límite inferior y superior. Estas marcas se utilizan como valores representativos de cada clase en cálculos posteriores.

1.5 Cálculo de frecuencia absoluta
Ecuación teórica:

$$f_i = \#\{x : L_i \leqslant x < L_s\}$$

Implementación en código:

```
f.abs <- numeric(length(lims.inf))
for (i in seq_along(lims.inf)) {
f.abs[i] <- sum(datos >=lims.inf[i]
&datos < lims.sup[i])
}
```

La frecuencia absoluta cuenta cuántas observaciones caen dentro de cada intervalo. Primero se inicializa un vector numérico con longitud igual al número de clases. Luego, mediante un bucle `for`, se recorre cada intervalo y se utiliza una operación lógica (>= y <) para verificar qué datos pertenecen a ese intervalo. La función `sum()` cuenta el número de valores que cumplen ambas condiciones simultáneamente (operador `&`). Es importante notar que los intervalos son cerrados por la izquierda y abiertos por la derecha, siguiendo la notación $[L_i, L_s)$.

1.6 Cálculo de frecuencia relativa
Ecuación teórica:

$$h_i = \frac{f_i}{N}$$

Implementación en código:

```
f.rel <- f.abs / N
```

La frecuencia relativa expresa la proporción o el peso que cada clase representa respecto al total de observaciones. Se obtiene simplemente dividiendo cada frecuencia absoluta entre N. Esta medida facilita comparaciones entre diferentes conjuntos de datos con tamaños distintos, ya que normaliza los valores a una escala común entre 0 y 1 (o 0 % y 100 %).

1.7 Cálculo de frecuencia acumulada
Ecuación teórica:

$$F_i = \sum_{k=1}^{i} f_k$$

Implementación en código:

```
f.ac <- cumsum(f.abs)
```

La frecuencia acumulada indica cuántas observaciones hay hasta cierta clase inclusive. La función `cumsum()` (cumulative sum) calcula eficientemente esta suma acumulativa, donde cada elemento representa la suma de todas las frecuencias absolutas desde la primera clase hasta la clase actual. Este valor es fundamental para construir ojivas y calcular percentiles.

1.8 Producto $f_i \times X_i$
Ecuación teórica:

$$f_i \cdot X_i$$

Implementación en código:

```
fixi <- f.abs * marca.de.clase
```

Este producto multiplica cada frecuencia absoluta por su marca de clase correspondiente. El resultado es esencial para calcular la media aritmética ponderada y otros estadísticos de tendencia central. Al multiplicar elemento por elemento (operación vectorizada en R), obtenemos una columna que luego será sumada para diversos cálculos.

1.9 Construcción de la tabla final
Implementación en código:

```
tabla.frecuencias <- data.frame(
  Limite_Inferior = lims.inf,
  Limite_Superior = lims.sup,
  Marca_de_Clase = marca.de.clase,
  Frecuencia_Absoluta = f.abs,
  Frecuencia_Relativa = round(f.rel, 4),
  Frecuencia_Acumulada = f.ac,
  FiXi = fixi
)
```

Todos los valores calculados se integran en un `data.frame`, que es la estructura de datos tabular estándar en R. Cada columna recibe un nombre descriptivo que facilita su identificación y uso posterior. La frecuencia relativa se redondea a 4 decimales mediante `round()` para mejorar la legibilidad sin perder precisión significativa.

Salida de la función
Implementación en código:

```
return(list(tabla = tabla.frecuencias,
datos = datos))
```

La función retorna una lista con dos elementos: la tabla de frecuencias completa y los datos originales sin procesar. Esta estructura permite flexibilidad, ya que algunos gráficos (como histogramas con datos continuos) pueden requerir acceso a los datos brutos, mientras que otros (como polígonos de frecuencias) trabajan directamente con la tabla agrupada. Al devolver ambos elementos, la función se convierte en una herramienta completa y versátil para el análisis estadístico posterior.

2. Medias y medidas de tendencia central
Función: calcular_medias()

Esta función fue diseñada para calcular las principales medidas de tendencia central a partir de una tabla de frecuencias previamente generada. Cada medida estadística se implementó siguiendo su definición matemática formal, traduciendo las fórmulas teóricas al lenguaje del software R de manera precisa.

Extracción de datos iniciales

La función comienza extrayendo los elementos fundamentales de la tabla de frecuencias: las marcas de clase (x_i), las frecuencias absolutas (f_i), el total de observaciones (N) y la amplitud de los intervalos. Estos valores son la base para todos los cálculos posteriores.

2.1 Media Aritmética
Ecuación teórica:

A partir de la ecuación 5, la cual calcula la media aritmética para un conjunto de datos agrupados.

$$\bar{x} = \mu = \frac{\sum_{i=1}^{N} x_i}{N}$$

Implementación en código:

```
ma <- round(sum(tabla$FiXi) / N, 4)
```

La media aritmética se obtiene sumando los productos de frecuencias por marcas de clase (columna F_iX_i de la tabla) y dividiendo entre el total de observaciones.

2.2 Media Armónica
Ecuación teórica

A partir de la ecuación 6, la cual calcula la media armónica para un conjunto de datos agrupados.

$$H = \frac{N}{\sum_{i=1}^{k} \frac{f_i}{x_i}}$$

Implementación en código:

```
sum_fi_sobre_xi <- sum(fi / xi)
ma_armonica <- round(N / sum_fi_
sobre_xi, 4)
```

Esta media es útil para promediar tasas o razones. Se calcula dividiendo el total de observaciones entre la suma de los cocientes f_i/x_i.

Esta media es útil para promediar tasas o razones. Se calcula dividiendo el total de observaciones entre la suma de los cocientes f_i/x_i.

2.3 Media Geométrica
Ecuación teórica:

A partir de la ecuación 7, la cual calcula la media geométrica para un conjunto de datos agrupados. Se define como el valor que mantiene constante el producto ponderado de las observaciones por sus frecuencias.

$$G = \sqrt[N]{\prod_{i=1}^{k} x_i^{f_i}}$$

Implementación en código:

```
sum_fi_por_log_xi <-
sum(fi * log(xi))
log_ma_geometrica <-
sum_fi_por_log_xi/N
ma_geometrica<-round(exp(log_ma_geome
trica), 4)
```

Para evitar el cálculo de productos muy grandes, aplicamos logaritmos naturales y luego recuperamos el valor original con la función exponencial.

2.4 Media Cuadrática
Ecuación teórica:

A partir de la ecuación 8, la cual calcula la media cuadrática para un conjunto de datos agrupados. Se define como una medida estadística que se usa para calcular un valor promedio que toma en cuenta la magnitud de los datos sin importar su signo.

$$C = \sqrt{\frac{\sum_{i=1}^{k} f_i \cdot x_i^2}{N}}$$

Implementación en código:

```
sum_fi_por_xi_cuadrado <-
sum(fi *(xi^2))
```

```
ma_cuadratica <-
round(sqrt(sum_fi_por_xi
_cuadrado / N), 4)
```

También conocida como media cuadrática o RMS (Root Mean Square), se calcula elevando al cuadrado cada marca de clase, multiplicando por su frecuencia, promediando y extrayendo la raíz cuadrada.

2.5 Mediana

Ecuación teórica:

A partir de la ecuación 10, la cual calcula la media geométrica para un conjunto de datos agrupados.

$$Me = L_i + \left(\frac{\frac{N}{2} - F_{a-1}}{f_i} \right) \cdot C$$

Implementación en código:

```
KN <- N/2
indice_mediana <- match(TRUE, tabla$
Frecuencia_Acumulada >= KN)
Li <- tabla$Limite_Inferior
[indice_mediana]fi_mediana <-
tabla$Frecuencia_
Absoluta[indice_mediana]
Fa_anterior <- ifelse
(indice_mediana == 1, 0,tabla
$Frecuencia_Acumulada[indice_mediana
- 1])
mediana <- round(Li + ((KN -
Fa_anterior) / fi_mediana) *
amplitud, 4)
```

La mediana representa el valor central que divide la distribución en dos partes iguales. Primero calculamos $N/2$ para determinar la posición central. Luego, utilizamos la función `match()` para identificar la clase donde se encuentra la mediana (la primera clase cuya frecuencia acumulada supera $N/2$). La función `ifelse()` maneja el caso especial cuando la mediana está en la primera clase, asignando cero como frecuencia acumulada anterior. Finalmente, aplicamos la fórmula de interpolación dentro del intervalo correspondiente.

1. **Localización**: Se determina el índice de la clase que contiene la posición $K * N$ ($N/2$ para la Mediana), $N/4$ (para Q_1) mediante la búsqueda en la frecuencia acumulada.

2. **Interpolación**: Se aplica la fórmula de interpolación utilizando el Límite Inferior (L_i), la frecuencia acumulada anterior ($Fa - 1$), la frecuencia absoluta de la clase (fMe) y la amplitud (A) para obtener una estimación precisa. Esta metodología se replica para Q_1, Q_3, P_{10} y P_{90}.

Salida de resultados

La función retorna un `data.frame` con todas las medidas calculadas, redondeadas a 4 decimales para facilitar su lectura y análisis comparativo.

3. Momentos

En el desarrollo de esta función, fuimos traduciendo cada fórmula estadística a instrucciones en `R`. A continuación explicamos, paso a paso, cómo realizamos esta conversión desde las ecuaciones matemáticas reales al código del programa.

3.1 Identificación de Variables Básicas

Primero ubicamos las variables fundamentales de una tabla de distribución agrupada:
x_i = marca de clase
f_i = frecuencia absoluta
N = $\sum \mathrm{f}_i$

Implementación en código:

```
xi <- tabla$Marca_de_Clase
fi <- tabla$Frecuencia_Absoluta
FiXi <- tabla$FiXi
N <- sum(fi)
```

3.2 Cálculo de la Media

Indica el punto de equilibrio e los datos. Representa el valor que se obtiene al sumar todos

los datos de un conjunto e datos y dividimos entre el número total de observaciones. La ecuación 5 calcula la media aritmética para un conjunto de datos agrupados.

$$\bar{x} = \frac{\sum f_i x_i}{N}$$

Implementación en código:

```
media_aritmetica <- sum(FiXi) / N
```

3.3 Momentos respecto al origen

El K-ésimo momento respecto al origen (o momento crudo) de una variable aleatoria x, denotado como m_k ó μ_k, se define como el valor esperado de x elevado a la porgtencia k. La ecuación 21 calcula los momentos respecto al origen para un conjunto de datos agrupados.

$$\mu'_k = \frac{\sum f_i x_i^k}{N}$$

3.4 Momentos respecto a la media

Son medidas estadísticas que describen la forma de una distribución tomando como referencia la media aritmética. Se usan para analizar variabilidad, simetría de un conjunto de datos. La ecuación 23 calcula el segundo momento central respecto a la media para un conjunto de datos agrupados.

$$\mu_k = \frac{\sum f_i (x_i - \bar{x})^k}{N}$$

3.5 Momentos respecto a la mediana

Son análogos a los momentos respecto a la media, pero usando la mediana como punto de referencia. Se usan cuando buscas una medida más robusta frente a valores extremos (outliers). La siguiente ecuación calcula los momentos respecto a la mediana en un conjunto de datos agrupados.

$$M_k = \frac{1}{N} \sum_{i=1}^{N} (x_i - \tilde{x})^k$$

Implementación en código:

```
for (k in n_momentos) {
    mu_origen_arr[k]<-sum(fi*xi^k)
    /Nmu_media_arr[k]<-sum
    (fi*(xi- media_aritmetica)^k)/N
    mu_mediana_arr[k]<-sum(fi*(xi-
    mediana)^k)/N
}
```

3.6 Momentos adimensionales

Se utilizan para describir la forma de la distribuación (independientemente de su escala o dispersión), se utilizan los momentos centrales respecto a la media. Estos se obtienen al dividir el momento central (μ_k) por la desviación estándar (σ) elevada a la potencia k. La ecuación 26 calcula el cuarto momento central respecto a la media para un conjunto de datos agrupados.

$$a_k = \frac{\mu_k}{\sigma^k} = \frac{\sum_{i=1}^{k} f_i (x_i - \mu)^k}{\left(\sum_{i=1}^{k} f_i (x_i - \mu)^2 \right)^{k/2}}$$

Implementación en código:

```
mu_adimensional_arr[k],
<- mu_media_arr[k],
/ (desviacion_estandar^k)
```

4. Varianza y Desviación Estándar

4.1 Varianza

Es el promedio de las diferencias al cuadrado entre cada observación y la media del conjunto. La ecuación 17 calcula la varianza para un conjunto de datos agrupados. Se elevan al cuadrado por dos razones:

- Para que las desviaciones negativas no se anulen con las positivas.
- Para dar más peso a las desviaciones más grandes.

$$\mu_2 = \frac{\sum f_i (x_i - \bar{x})^2}{N}$$

Implementación en código:

```
mu_2 <- sum(fi * (xi - media_arit
metica)^2) / N
desviacion_estandar <- sqrt(mu_2)
```

4.2 Desviación estándar

Es una medida de extensión o variabilidad en la estadística descriptiva. Se utiliza para calcular la variación o dispersión en la que los puntos de datos individuales difieren de la media. Es la distancia promedio de cada dato del conjunto.

- Es la raíz cuadrada de la varianza.
- Es la medida más utilizada.
- Al tomar la raíz cuadrada, se regresa a las unidades origianles de los datos, lo que hace más fácil de interpretar.

La ecuación 17 calcula la desviación estándar para un conjunto de datos agrupados.

$$\sigma = \sqrt{\frac{\sum_{i=1}^{k} f_j(x_i - \mu)^2}{N}}$$

5. Mediana, Cuartiles y Percentiles

5.1 Cuantiles

Son medidas de posición que dividen un conjunto de datos ordenados en partes iguales y permiten identificar valores representativos en distintas proporciones.

- **Cuártiles:** Dividen en cuatro partes iguales, se denotan como: Q_1, Q_2, Q_3
- **Deciles:** Dividen en diez partes iguales, se denotan como: $D_1, D_2, D_3 ... D_9$
- **Percentiles:** Dividen en cien partes iguales, se denotan como: $P_1, P_2, P_3 ... P_{99}$

La ecuación 12 calcula la posición del cuantil para un conjunto de datos agrupados.

$$P_k = L_i + \left(\frac{k - F_{i-1}}{f_i}\right) C$$

Implementación en código:

```
encontrar_parte <- function(K_pos){
    indice <- match(TRUE, tabla$
    Frecuencia_Acumulada >= K_pos)
    Li <- tabla$Limite_Inferior
    [indice]
    fi_clase <- tabla
    $Frecuencia_Absoluta[indice]
    Fa_anterior <- ifelse(indice == 1,
    0, tabla$Frecuencia_Acumulada
    [indice - 1])
    return(Li + ((K_pos - Fa_anterior)
    / fi_clase) * amplitud)
}
```

6. Moda aproximada (ecuación de Pearson)

Se refiere a la aproximación de la moda en distribuciones ligeramente asimétricas cuando no puede obtenerse directamente de los datos. En la siguiente ecuación se muestra:

$$\text{Moda} \approx 3 \cdot \text{Mediana} - 2 \cdot \text{Media}$$

Implementación en código:

```
moda_aprox <- 3 * mediana - 2,
* media_aritmetica
```

7. Sesgos

7.1 Primer sesgo y segundo sesgo

Es una prueba que mide la relación estadística entre dos variables continuas. Si la asociación entre los elementos no es lineal, entonces el coeficiente no se encuentra representado adecuadamente.

La ecuación 28 calcula el primer coeficiente de sesgo de Pearson para un conjunto de datos agrupados.

$$Sesgo_1 = \frac{\mu - Moda}{\sigma}$$

La ecuación 29 calcula el segundo coeficiente de sesgo de Pearson para un conjunto de datos agrupados.

$$Sesgo_2 = \frac{3(\mu - Mediana)}{\sigma}$$

Implementación en código:

```
Sk_p1 <- 3 * (media_aritmetica,
- mediana),
/ desviacion_estandar
Sk_p2 <- (media_aritmetica,
- moda_aprox),
/ desviacion_estandar
```

7.3 Sesgo cuártilico

Divide la distribución en cuartiles Q_1 (primer cuartil), Q_2 (mediana) y Q_3 (tercer cuartil), y mide la asimetría relativa de los datos en torno a la mediana. La ecuación 30 calcula el coeficiente cuartil de sesgo para un conjunto de datos agrupados.

$$k_B = \frac{Q_3 + Q_1 + 2Q_2}{Q_3 - Q_1}$$

7.4 Curtosis y Exceso de Curtosis

7.4.1 Curtosis

Mide que tan puntiaguda es en comparación con la distribución normal. Una alta curtosis indica que la varianza se debe a valores atípicos (outliers), infrecuentes y extremos, en lugar de a valores moderados y frecuentes. El sesgo y la curtosis miden lo mismo, pero usan una referencia distinta.

Referencia: La curtosis de una distribución normal es 3. Para ello, casi siempre podemos usar el exceso de curtosis. La ecuación 32 calcula la curtosis para un conjunto de datos agrupados.

$$\text{Curtosis} = \frac{\mu_4}{\sigma^4}$$

7.4.2 Exceso curtosis

La **curtosis** mide la forma de la distribución de los datos, específicamente el grado de concentración de los valores alrededor de la media. Según el valor del **exceso de curtosis** se clasifican los tipos de distribución. La ecuación 32 calcula el exceso de curtosis para un conjunto de datos agrupados.

$$\text{Curtosis} = \frac{\mu_4}{\sigma^4} - 3 = Curtosis - 3$$

Implementación en código:

```
Curtosis <- mu_media_arr[4] /,
(mu_2^2)
Exceso_Curtosis <- Curtosis - 3
```

7.5 Clasificación de la Distribución

Definimos el tipo de distribución según el exceso de curtosis:

Basado en β_2 = Exceso de curtosis:

- **Leptocúrtica** ($\beta_2 > 0$): lepto = ”delgado”, pico agudo y colas pesadas. Más propensa a outliers extremos.
- **Mesocúrtica** ($\beta_2 = 0$): meso - ”medio”, igual que la distribución normal.
- **Platicúrtica** ($\beta_2 < 0$): platy = ”Plano”, pico plano y colas ligeras, menos propensa a outliers.

Implementación en código:

```
tipo <- ifelse(Exceso_Curtosis > 0,
"Leptocúrtica",
           ifelse(Exceso_Curtosis,
           < 0, "Platicúrtica",
           "Mesocúrtica"))
```

8. Construcción del Resultado Final

Finalmente juntamos todos los valores en un `data.frame`:

```
df_final <- rbind,
(df_momentos, df_resumen)
```

Finalizando de esta manera la metodología de la realización del código en el software R, se establece que cada procedimiento aplicado permitió organizar de forma adecuada el proceso de análisis estadístico. Desde la preparación de los datos hasta la obtención de resultados numéricos y gráficos, el uso de R facilitó una ejecución precisa, reproducible y eficiente. Esta metodología proporciona una base sólida para garantizar la validez de los resultados obtenidos y para sustentar la interpretación final dentro del desarrollo del proyecto.

III. Resultados

En este apartado se presentan los resultados obtenidos a partir del análisis estadístico realizado con el software R. Las imágenes incluidas corresponden a gráficas, diagramas y tablas generadas por el programa, las cuales permiten visualizar de manera clara y comprensible los patrones, tendencias y relaciones encontradas en los datos analizados. Cada resultado se acompañará de una breve explicación para facilitar la interpretación y comprensión de la información obtenida en el contexto de nuestro estudio.

A continuación, en la Figura 6 se presenta la **tabla de frecuencias** elaborada a partir de los datos analizados con R. Esta tabla permite observar la distribución de los valores en las diferentes categorías o intervalos, así como la frecuencia con la que cada valor o rango de valores se presenta en el conjunto de datos. Su análisis facilita la comprensión de patrones y tendencias dentro de la información recopilada.

En la Figura 7 se presentan las **medidas de tendencia central** calculadas a partir de los datos analizados con el software R. Estas medidas facilitan la comprensión de la distribución de los datos y proporcionan un punto de referencia para comparar y analizar la variabilidad dentro del estudio.

	Limite_Inferior	Limite_Superior	Marca_de_Clase	Frecuencia_Absoluta
1	38.95	40.95	39.95	522
2	40.95	42.95	41.95	375
3	42.95	44.95	43.95	351
4	44.95	46.95	45.95	417
5	46.95	48.95	47.95	447
6	48.95	50.95	49.95	459
7	50.95	52.95	51.95	448
8	52.95	54.95	53.95	437
9	54.95	56.95	55.95	450
10	56.95	58.95	57.95	448
11	58.95	60.95	59.95	645
12	60.95	62.95	61.95	1
13	62.95	64.95	63.95	0

	Frecuencia_Relativa	Frecuencia_Acumulada	FiXi
1	0.1044	522	20853.90
2	0.0750	897	15731.25
3	0.0702	1248	15426.45
4	0.0834	1665	19161.15
5	0.0894	2112	21433.65
6	0.0918	2571	22927.05
7	0.0896	3019	23273.60
8	0.0874	3456	23576.15
9	0.0900	3906	25177.50
10	0.0896	4354	25961.60
11	0.1290	4999	38667.75
12	0.0002	5000	61.95
13	0.0000	5000	0.00

Figura 6. Tabla de frecuencias

Media_Aritmetica	Media_Armonica	Media_Geometrica	Media_Cuadratica	Mediana
50.4504	49.5781	50.0172	50.8735	50.6406

Media_Aritmetica	Mediana	RSI	RSP	Desviacion_Media	Varianza
50.4504	50.6406	5.6485	9.2685	5.6698	42.8688

Desviacion_Estandar	Zscore_3ra_Frecuencia	Coef_Dispersion_v	Coef_IQR
6.5474	-0.9928	0.1298	0.1116

Figura 7. Medias y medidas de tendencia central

En la Figura 8 se presentan los resultados de los **momentos y sesgos** obtenidos a partir del análisis realizado en R. Los momentos permiten describir características importantes de la distribución de los datos, como su dispersión, simetría y forma general, mientras que los sesgos indican la asimetría de la distribución respecto a la media. Estas medidas ayudan a comprender mejor la estructura de los datos y a identificar posibles desviaciones respecto a una distribución equilibrada.

A continuación se observa en la Figura 9 **la gráfica ojiva** obtenida con R, la cual permite visualizar de manera acumulativa la frecuencia de los datos. Esta representación facilita la identificación de la distribución acumulada de los valores y ayuda a interpretar tendencias, comparaciones y patrones dentro del conjunto de datos de forma clara y rápida.

Metrica	Valor
m1_origen	50.4504
m2_origen	2588.1117
m3_origen	134869.2399
m4_origen	7130632.9019
m1_media	0
m2_media	42.8688
m3_media	-27.5247
m4_media	3257.1815
m1_mediana	-0.1902
m2_mediana	42.905
m3_mediana	-51.9967
m4_mediana	3287.4352
m1_adimensional	0
m2_adimensional	1
m3_adimensional	-0.0981
m4_adimensional	1.7724
Media	50.4504
Mediana	50.6406318082789
Moda_aprox	51.0210954248366
Desviacion_Estandar	6.54742696331926
Sesgo_Pearson_1	-0.0871633128607305
Sesgo_Pearson_2	-0.0871633128607305
Sesgo_Cuartil	-0.00575411135596182
Curtosis	1.77239007327872
Exceso_Curtosis	-1.22760992672128
Tipo_Distribucion	Platicúrtica

Figura 8. Momentos y sesgos

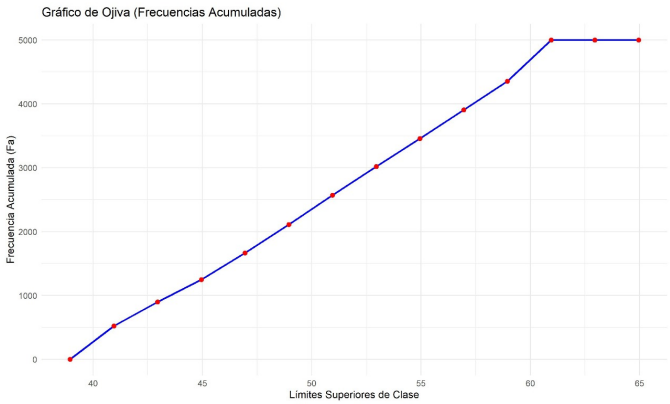


Figura 9. Gráfica Ojiva

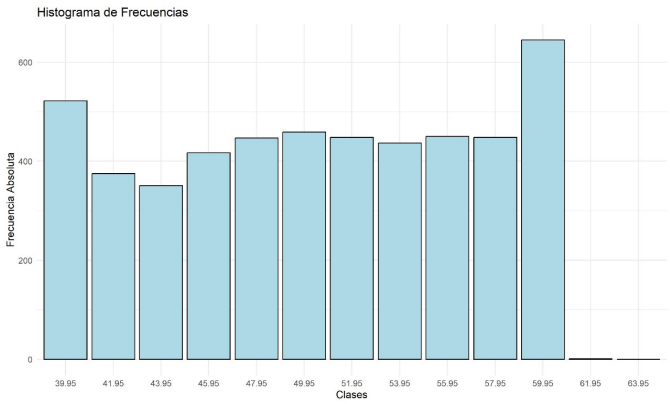


Figura 10. Histograma de frecuencias

En la Figura 10 se muestra **la gráfica de histograma de frecuencias** generado con R, el cual representa gráficamente la distribución de los datos en intervalos específicos. Esta herramienta permite observar la frecuencia de aparición de los valores, identificar patrones y tendencias, y analizar de manera visual la dispersión y concentración de los datos dentro del conjunto estudiado.

En la Figura 11 se presenta **la tabla del polígono de frecuencias** elaborada con R. Esta tabla muestra los puntos correspondientes a las frecuencias de cada intervalo de datos, los cuales servirán para construir el polígono de frecuencias. Su análisis permite identificar patrones y comparaciones de manera visual, facilitando la comprensión de la distribución de los datos dentro del conjunto estudiado.

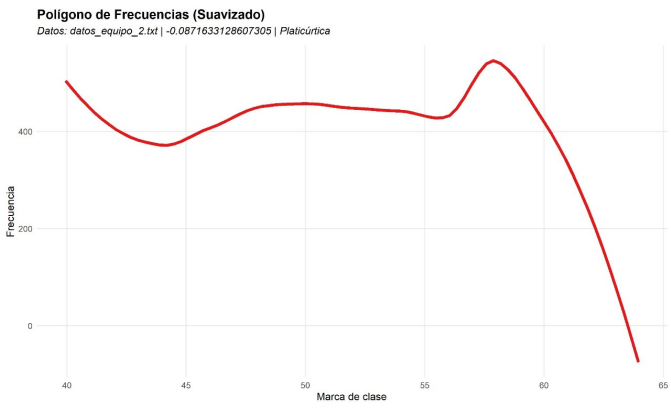


Figura 11. Histograma

IV. Análisis y Discusión

A partir de la tabla de distribución de frecuencias y de las medidas estadísticas obtenidas, se puede analizar el comportamiento general de los datos y la forma de la distribución.

1. Análisis descriptivo general

Los datos con los que se contaron fueron de 5000 observaciones, lo cual es una muestra grande y estadísticamente estable. En la tabla de frecuencias se observa que los valores se encuentran aproximadamente entre 39 y 64, distribuidos en intervalos definidos mediante la regla de Sturges.

Los valores más frecuentes se concentran alrededor de los intervalos donde las marcas de clase son aproximadamente 40, 45, 50, 55 y 60, lo cual coincide con el comportamiento que se aprecia en el histograma y el polígono de frecuencias.

Esto indica que la variable no presenta valores extremos, y la mayoría de los datos se distribuye alrededor del centro.

La media aritmética obtenida fue:

$$\bar{x} = 50{,}4504$$

Mientras que la mediana es:

$$\tilde{x} = 50{,}6406$$

La cercanía entre ambas medidas indica una asimetría prácticamente nula. La moda aproximada obtenida fue:

$$\text{Moda} \approx 51{,}02$$

Coincidiendo con las clases donde se concentra mayor frecuencia.

La cercanía entre la media, la mediana y la moda indica que la distribución es prácticamente simétrica, tiene ausencia de valores atípicos significativos y su comportamiento estable alrededor del centro.

Cuando las tres medidas son cercanas, se dice que existe asimetría mínima, lo que también fue confirmado con los análisis posteriores del sesgo.

2. Dispersión

La varianza obtenida fue:

$$s^2 = 42{,}87$$

La desviación estándar correspondiente fue:

$$s = 6{,}5474$$

Estos valores indican una dispersión moderada alrededor de la media.

El coeficiente de variación:

$$CV = 0{,}1298$$

Equivalente al 12.98 %, confirma que la variabilidad del conjunto de datos es baja a moderada, lo cual sugiere homogeneidad.

El coeficiente basado en el rango intercuartílico también es bajo:

$$IQR = 0{,}1116$$

Reforzando la idea de una dispersión baja.

Un coeficiente de variación menor al 20 % indica:

- Variabilidad baja a moderada.
- Datos relativamente homogéneos.

El IQR bajo confirma que el 50 % central de los datos está concentrado cerca de la mediana. Esto concuerda con la forma visual del histograma, el cual no presenta colas largas ni dispersión excesiva.

3. Momentos y forma de distribución

3.1 Sesgo y asimetría

El tercer momento adimensional:

$$\gamma_1 = -0{,}0981$$

junto con el sesgo de Pearson:

$$\text{Sesgo} = -0{,}087$$

Indican que la distribución presenta una asimetría leve hacia la izquierda, aunque prácticamente puede considerarse simétrica.

Sabemos que:

- **Valor cercano a cero:** Distribución casi simétrica.
- **Signo negativo:** Ligera inclinación hacia la izquierda

Pero el valor absoluto es menor a 0.1, considerado prácticamente simétrico. Esto es coherente con las medidas centrales y con la forma del histograma.

3.2 Curtosis

La curtosis obtenida fue:

$$\gamma_2 = 1{,}772$$

El exceso de curtosis es el siguiente:

$$\gamma_2 - 3 = -1{,}228$$

Sabemos que:

- **Exceso negativo:** Distribución platicúrtica.

Esto quiere decir:

- Distribución más aplanada que la normal.
- Más datos cerca de los valores moderados.

Debido a que el exceso es negativo, la distribución se clasifica como platicúrtica, es decir, más aplanada que una distribución normal y con colas menos pesadas.

4. Análisis de las gráficas

A partir de la tabla de frecuencias construida previamente, se generaron tres representaciones gráficas: la ojiva, el polígono de frecuencias suavizado y el histograma. Cada una aporta información complementaria acerca de la distribución de los datos, permitiendo una interpretación más completa del comportamiento de la variable analizada.

4.1 Gráfica Ojiva

La ojiva, que representa las frecuencias acumuladas en función de los límites superiores de clase, muestra una curva ascendente continua, característica de distribuciones donde no existen decrementos en la acumulación de datos. El comportamiento casi lineal del tramo principal indica que la variable presenta una acumulación progresiva y estable en la mayoría de los intervalos.

Se observó que la curva presenta un incremento notable alrededor de la clase con límite superior cercano a 60, lo cual coincide con la clase de mayor frecuencia absoluta. Este punto evidencia dónde se concentra una mayor proporción de observaciones. Asimismo, la meseta al final de la gráfica demuestra que después de cierta clase ya no se suman nuevas observaciones, lo que confirma que el rango superior prácticamente no contiene datos.

4.2 Gráfica polígono de frecuencias suavizado

El polígono suavizado permite visualizar la tendencia general de la distribución sin la rigidez de un polígono tradicional. La gráfica presenta una forma ondulante con una ligera caída inicial y un ascenso moderado hacia la región central. Posteriormente, se aprecia un pico significativo alrededor de la marca de clase cercana a 59–60, lo que coincide con el intervalo de mayor frecuencia reportado en la tabla.

La tendencia general sugiere una distribución ligeramente sesgada a la izquierda, coherente con el valor negativo del sesgo calculado. Además, la presencia de varios tramos relativamente planos indica que las frecuencias no presentan variaciones abruptas entre clases, lo cual es consistente con la naturaleza casi uniforme de gran parte del conjunto

de datos. Finalmente, hacia el extremo derecho la gráfica desciende de manera pronunciada, debido a la baja cantidad de observaciones en los últimos intervalos.

4.3 Gráfica de histograma de frecuencias

El histograma muestra de manera clara cómo se distribuyen las frecuencias por clase. En la gráfica se observa que los intervalos centrales, especialmente aquellos cercanos a 50–58, contienen la mayor parte de los datos, lo cual coincide con el rango donde se ubican los valores las medidas de tendencia central.

La barra correspondiente al intervalo cercano a 60 es visiblemente la más alta, reforzando la idea de que existe un ligero agrupamiento de datos en esa zona. Por otro lado, las clases situadas después de 60 presentan frecuencias extremadamente bajas, incluyendo una clase en la cual no se registraron datos, lo que genera un marcado contraste con el resto del histograma.

En conjunto, el histograma confirma que la distribución es ligeramente platicúrtica, ya que la altura de las barras no presenta un pico extremadamente pronunciado, sino que mantiene una forma más extendida. Esto concuerda con el valor de curtosis menor que 3 obtenido en los cálculos previos.

Conclusiones del Análisis de datos

A partir del análisis conjunto de las medidas numéricas y las representaciones gráficas obtenidas, concluimos que los datos presentan un comportamiento coherente y consistente entre ambos enfoques. Las medidas de tendencia central indican que la mayor parte de las observaciones se concentran en torno a los valores de 50 a 51, lo cual se confirma en el histograma y en el polígono suavizado, donde se observa una clara acumulación de frecuencia en los intervalos centrales. La cercanía entre la media, mediana y moda aproximada demuestra que la distribución no presenta asimetrías pronunciadas, lo cual coincide con el sesgo ligeramente negativo calculado.

La desviación estándar y la varianza indican que existe una dispersión moderada en los datos, rasgo que también se observa en la forma extendida del histograma y en la platicurtosis evidenciada por el valor de curtosis menor a 3. Esto confirma que la distribución es más aplanada de lo que sería en una distribución normal estricta. Por otro lado, la ojiva refleja una acumulación progresiva y estable, destacando la clase de mayor frecuencia y reforzando la interpretación cuantitativa de los resultados.

En conjunto, tanto los cálculos estadísticos como las gráficas señalan que la distribución presenta una estructura bien definida, con una concentración central amplia, un sesgo casi nulo y una forma platicúrtica. La coherencia entre ambos tipos de análisis nos permitió validar las conclusiones obtenidas y comprender de manera más completa el comportamiento de la variable estudiada.

En resumen, los datos analizados presentan las siguientes características principales:

- **Simetría casi perfecta:** El sesgo negativo es muy pequeño y no afecta significativamente la forma de la distribución.
- **Dispersión moderada y homogénea:** El CV del 12.98 % muestra consistencia entre los valores, sin variabilidad excesiva.
- **Distribución platicúrtica:** Los datos se concentran de manera más uniforme que en una distribución normal, sin gran presencia de valores extremos (outliers).
- **Medidas de tendencia central alineadas:** Media, mediana y moda prácticamente iguales, lo que indica estabilidad.
- **Gráficos coherentes:** Tanto el histograma como la ojiva respaldan la forma suave y el comportamiento regular de los datos.
- **Gráficos coherentes:** Tanto el histograma

como la ojiva respaldan la forma suave y el comportamiento regular de los datos.

En conclusión, la distribución estudiada puede describirse como: **"Simétrica, homogénea, sin valores extremos y con variabilidad moderada"**.

V. Conclusiones

Conclusión general del análisis estadístico

El análisis estadístico realizado mediante el software R permitió caracterizar de forma completa la distribución de los datos estudiados. Las medidas de tendencia central mostraron que la media, mediana y moda presentan valores muy cercanos, lo que evidencia una distribución prácticamente simétrica y sin presencia de valores atípicos que afecten su comportamiento. La variabilidad observada, reflejada en la desviación estándar y el coeficiente de variación, indica una dispersión baja a moderada, lo que demuestra que los datos son relativamente homogéneos.

El estudio de los momentos confirmó esta estabilidad: el sesgo resultó mínimatente negativo, por lo que la distribución puede considerarse simétrica. Asimismo, la curtosis presentó un exceso negativo, clasificando a la distribución como platicúrtica, es decir, con un perfil más aplanado y con baja presencia de valores extremos. Todo esto sugiere que los valores se concentran de manera equilibrada alrededor del centro, sin alta probabilidad en los extremos.

Finalmente, las representaciones gráficas como el histograma, la ojiva y el polígono de frecuencias respaldaron visualmente los resultados numéricos, confirmando la consistencia general del comportamiento de los datos. En conjunto, el análisis refleja un conjunto de datos estable, bien distribuido y con propiedades favorables para su interpretación estadística. Estos resultados muestran la funcionabilidad del software R como herramienta precisa y eficiente para el manejo, procesamiento y visualización de información estadística.

Conclusión general acerca del proyecto

A lo largo del desarrollo de este proyecto en el software `R`, nuestro equipo logró integrar diversos conceptos estadísticos y computacionales en un solo flujo de trabajo automatizado. El archivo `main.R` se convirtió en el eje central del programa, ya que coordina la carga de datos, la ejecución de las funciones y la generación de gráficos a partir de los valores obtenidos. Desde el inicio, uno de los principales objetivos fue crear un sistema modular que permitiera analizar cualquier conjunto de datos agrupados en clases, facilitando el cálculo de medidas de tendencia central, momentos estadísticos y representaciones gráficas.

Durante el proceso nos dimos cuenta de la utilidad de estructurar el proyecto mediante funciones almacenadas en archivos separados. Esto hizo el código más limpio, más fácil de depurar y más escalable. Sin embargo, implementar esta organización no fue rápido, ya que tuvimos que aprender a manejar las funciones, coordinar rutas de trabajo y garantizar que cada script fuera capaz de comunicarse correctamente con el resto del proyecto.

Una de las partes más desafiantes del proyecto fue traducir las fórmulas matemáticas a código funcional en el software `R`. Conceptos como momentos centrales, medidas de tendencia central y de sesgo fueron fáciles de entender dentro de la teoría y aplicando dichas ecuaciones a problemas prácticos, pero al convertirlos en funciones computacionales surgieron diversas dificultades dificultades. Tuvimos que analizar cada ecuación, descomponerla en operaciones básicas y reescribirlas para que fueran compatibles con los vectores del lenguaje en R. El manejo de índices, el uso de operaciones vectorizadas y la comprobación de errores fueron obstáculos que se manifestaban con frecuencia, pero nos ayudaron a comprender mejor la relación entre teoría estadística y la programación de esta.

Asimismo, la parte gráfica también implicó retos. El uso de `ggplot2` y la construcción

de histogramas, ojivas y polígonos suavizados nos obligó a comprender cómo generar capas visuales, personalizar títulos dinámicos y enlazar los resultados estadísticos con los elementos de los gráficos. Integrar estos valores directamente en los títulos requirió coordinar correctamente las salidas numéricas de nuestras funciones con el código visual de `ggplot2`.

Otro aprendizaje importante durante el desarrollo de este proyecto fue la interpretación conjunta de los resultados. Gracias a la automatización, pudimos observar cómo se relacionan las medidas de tendencia central con los momentos, el sesgo y la forma de la distribución. Esto facilitó el análisis completo del conjunto de datos sin tener que realizar cálculos manuales, permitiéndonos centrarnos en la interpretación estadística más que en el procedimiento numérico.

Como equipo consideramos que el proyecto fue altamente útil por varias razones:

1. Automatiza el análisis estadístico completo de datos agrupados: tabla, medidas, momentos y gráficas.
2. Nos permitió entender más profundamente cómo se implementan matemáticamente los conceptos estadísticos dentro de un lenguaje de programación.
3. Aprendimos a organizar un proyecto en el software `R` utilizando múltiples archivos y funciones modulares, lo cual es una práctica profesional importante.
4. Logramos dominar herramientas visuales como `ggplot2`, integrando resultados numéricos en representaciones gráficas interpretativas.
5. Las dificultades encontradas (en específico convertir fórmulas a código) fortalecieron nuestras habilidades de razonamiento lógico y programación.

En general, el proyecto no solo cumplió su función técnica, sino que también nos proporcionó experiencia valiosa en trabajo colaborativo, estructuración de código y aplicación práctica de la estadística.

REFERENCIAS

[1] Spiegel, M.R. & Stephens, L.J. (2008). *Estadística.*, Ed. McGrawHill.

[2] Singh Rayat, C. (2018). *Statistical Methods in Mediacal Research.* Ed. Springer.

[3] Sabo, R. & Boone, E. (2013) *Statistical Research Methods.* Ed. Springer.

[4] Scribbr. (s.f.). *Frequency distributions*. Recuperado el 14 de noviembre de 2025, de https://www.scribbr.com/statistics/frequency-distributions/

[5] GCFGlobal. (s.f.). *Estadística básica: ¿Qué es una tabla de frecuencias?* Recuperado el 14 de noviembre de 2025, de https://edu.gcfglobal.org/es/estadistica-basica/que-es-una-tabla-de-frecuencias/1/

[6] Nombre del canal. (Año). *Título del video* [Video]. YouTube. Recuperado de https://www.youtube.com/watch?v=XFjDGydsGvU

[7] PlandeMejora. (s.f.). *Histograma de frecuencias*. Recuperado de https://www.plandemejora.com/histograma-de-frecuencias/

[8] SixSigma DSI. (s.f.). ¿Qué es una distribución unimodal? Recuperado de https://sixsigmadsi.com/glossary/unimodal-distribution/

[9] QuestionPro. (s.f.). Desviación estándar. Recuperado de https://www.questionpro.com/blog/es/desviacion-estandar/

[10] CentroGeo. (s.f.). Recordando las medidas de tendencia central, dispersión y forma. En *Diplomado en Análisis de Información Geoespacial*. Recuperado de https://centrogeo.repositorioinstitucional.mx/jspui/bitstream/1012/161/1/17-Recordando%20las%20Medidas%20de%20Tendencia%20Central%2C%20de%20Dispersi%C3%B3n%20y%20de%20la%20Forma%20-%20%20Diplomado%20en%20An%C3%A1lisis%20de%20Informaci%C3%B3n%20Geoespacial.pdf

[11] QuestionPro. (s.f.). Coeficiente de correlación de Pearson. Recuperado de https://www.questionpro.com/blog/es/coeficiente-de-correlacion-de-pearson/